Jornada de Iniciação Científica

SEMANA DE INTEGRAÇÃO ACADÊMICA

Aprendizagem Profunda e IA Verde:

Caminhos Para Um Futuro Mais Sustentável

UNIRIO
UNIVERSIDADE FEDERAL DO ESTADO DO RIO DE JANEIRO

PROPGPI
PRÓ-REITORIA DE PÓS-GRADUAÇÃO, PESQUISA E INOVAÇÃO

DPQ
DIRETORIA DE PESQUISA

Discente: Vívian Rique Gil Ferraro

Professor Responsável: Pedro Nuno de Souza Moura

Coorientação: Daniel da Silva Costa

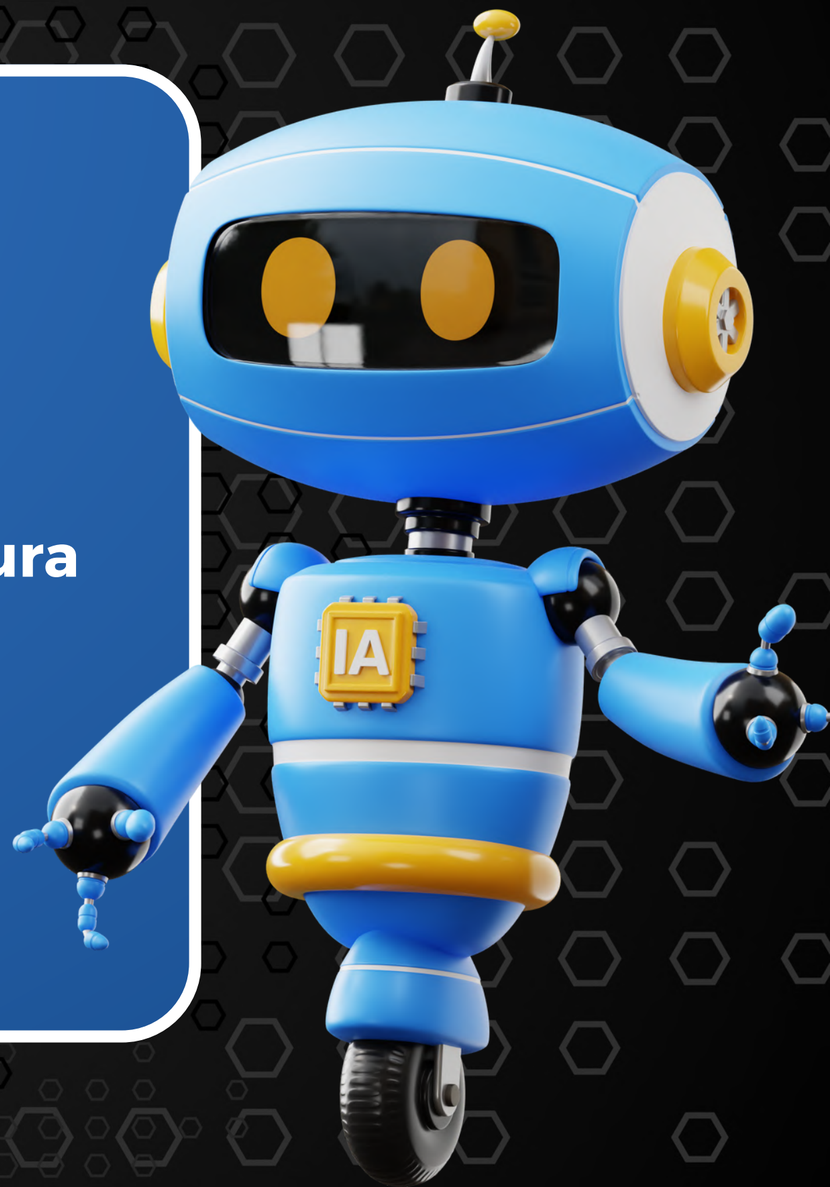

Aprendizagem Profunda

A aprendizagem profunda é um subcampo da inteligência artificial que se concentra na construção e treinamento de redes neurais.

- Modelos capazes de realizar tarefas complexas com grande precisão.

Aprendizagem Profunda

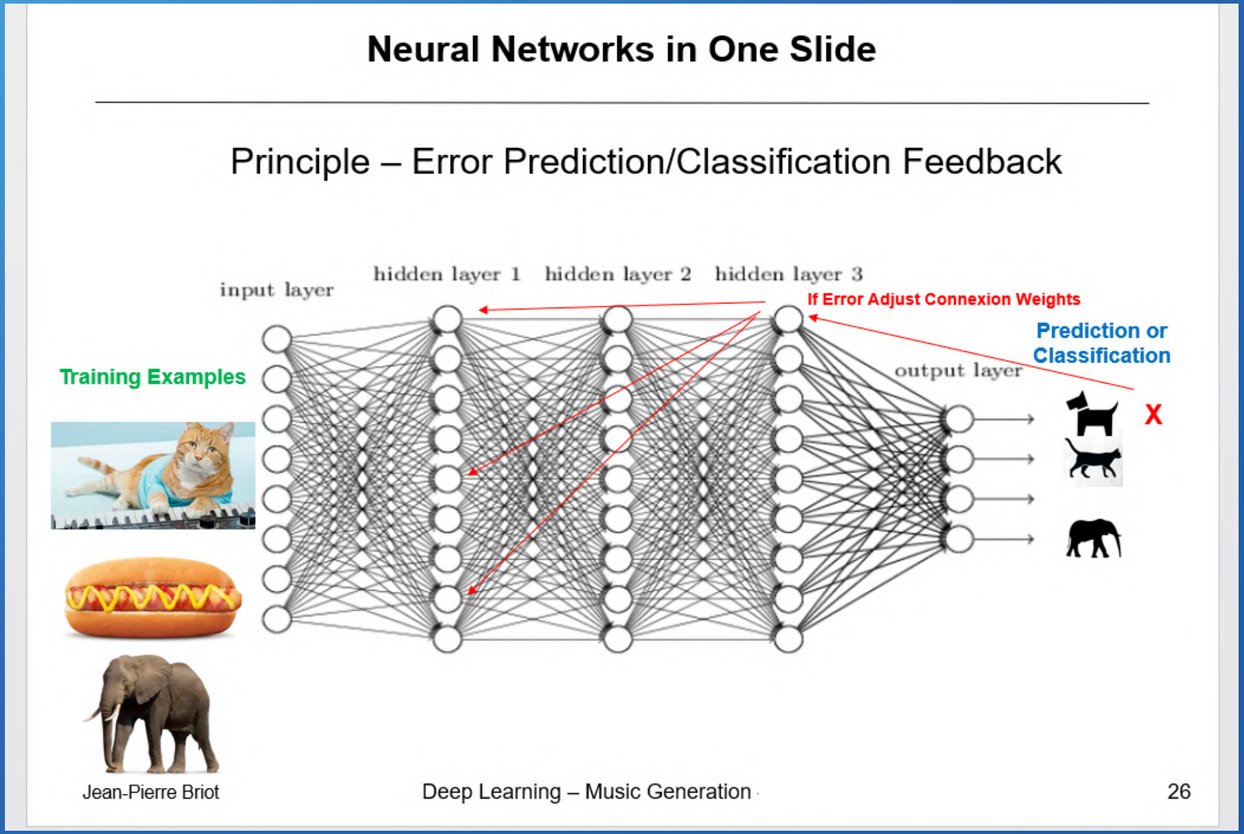

(BRIOT et al., 2020)

Modelos cada vez mais robustos, com grande capacidade de processamento.

Busca constante por maior precisão.

Aumento exponencial do consumo de energia e dos recursos computacionais.

Custos cada vez maiores

01
BERT-large

- 350 milhões de parâmetros

02
GPT2-XL

- 1,5 bilhão de parâmetros

03
GPT3

- 175 bilhões de parâmetros

04
GPT4

- superior a 1 trilhão de parâmetros

O que são parâmetros?

São valores numéricos que a rede usa para tomar decisões.

Funcionam como ‘regras’ internas da rede, que permitem uma compreensão mais profunda dos dados e a capacidade de fazer previsões mais precisas.

Experimentos

Base de dados:

MNIST

(LECUN, 1998)

Conjunto de treinamento com **60.000** exemplos

Conjunto de testes com **10.000** exemplos

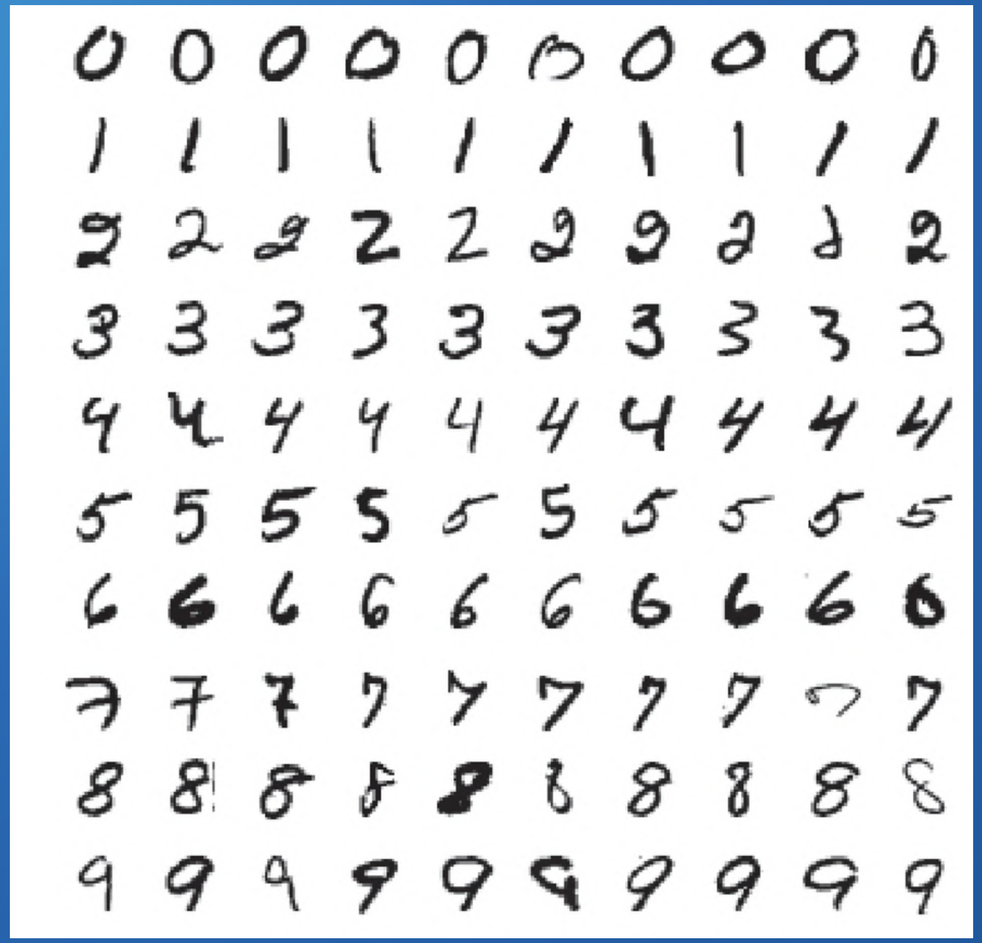

Experimentos

Rede utilizada:

LeNet-5

(LECUN et al., 1998)

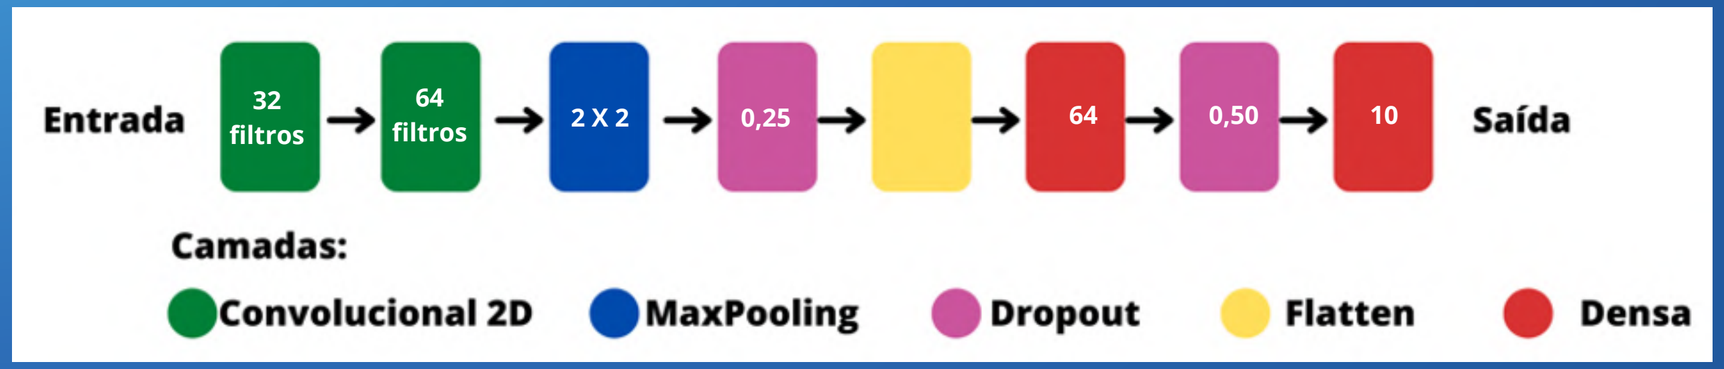

Número de parâmetros: 609.354

Experimentos

Rede utilizada:

AlexNet

(KRIZHEVSKY et al., 2017)

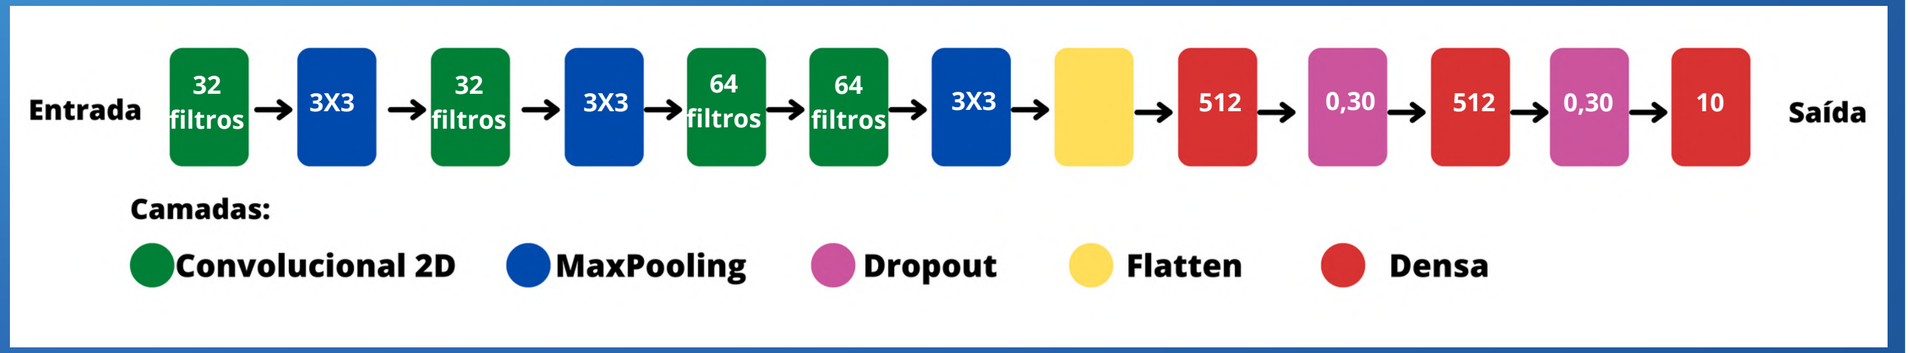

Número de parâmetros: 1.938.922

Métricas adotadas

Gasto Energético

- Tempo de treino
- Tempo de inferência
- Número de parâmetros
- Operações de ponto flutuante
- Consumo energético do Hardware

Desempenho

- Acurácia
- Precisão
- Recall
- F1-Score

Desenvolvimento

- Foram realizados 10 treinos, que geraram 10 modelos para cada rede.
- O modelo que obteve maior acurácia em cada rede foi escolhido para a inferência.
- O conjunto de dados de treino foi dividido em treino (80%) e validação (20%).
- O tamanho do batch foi de 128.
- Cada treino foi realizado em 20 épocas.

Características do ambiente de treino e testes

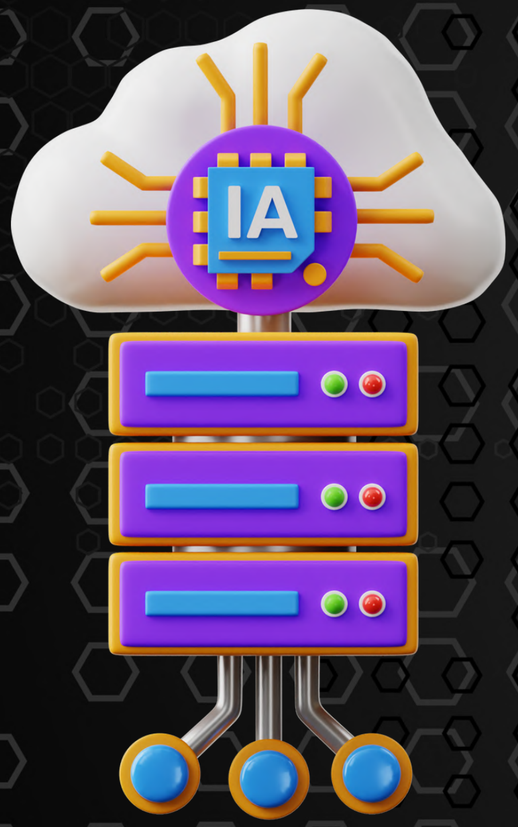

- Plataforma Google Colab
- GPU NVidia V-100
- 12 GB memória RAM

Principais recursos utilizados

- Linguagem Python
- Interface Jupyter Notebook
- Biblioteca TensorFlow
- Biblioteca Keras_flops para medir o número de FLOPS
- Biblioteca pyJoules para medir o consumo energético

Resultados

Métricas de consumo para cada rede

Modelos	Tempo de treino (segundos)	Tempo de inferência (milissegundos)	Operações de ponto flutuante (GFLOPS)	Consumo Energético (microjoules)	Número de Parâmetros
LeNet-5	**33,8262** (desvio padrão 3,6200)	**854**	**2,93**	**3956288** (desvio padrão 169868,8)	**609.354**
AlexNet	**76,645768** (desvio padrão 10,3636)	**1737,982**	**5,67**	**6889739,4** (desvio padrão 451840,7)	**1.938.922**

*Os valores para tempo de treino e consumo energético foram obtidos durante os treinos, através das média dos valores de cada modelo gerado pelas redes.

*O tempo de inferência foi obtido no teste como o modelo com maior acurácia de cada rede.

*O número de operações de ponto flutuante é constante para cada rede.

Unidades:

1 GFLOP = 1×10^{9} FLOPS

1 milissegundo = 1×10^{-3} segundos

1 microJoule = 1×10^{-6} Joules

Resultados

Desempenho de cada rede

Modelo	Acurácia	Precisão	Recall	F1-Score
LeNet-5	0,9929	0,992841	0,992858	0,992845
AlexNet	0,985	0,984997	0,984776	0,984865

*Valores obtidos durante a inferência.

* Valores normalizados

Resultados

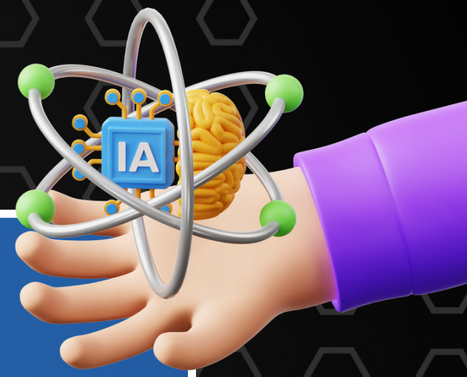

Matriz de confusão

LeNet-5

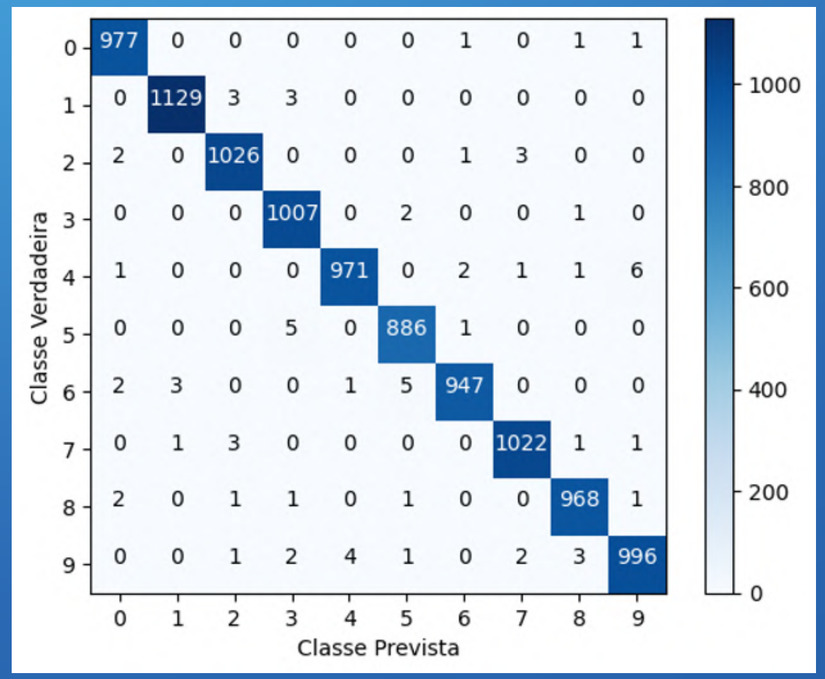

AlexNet

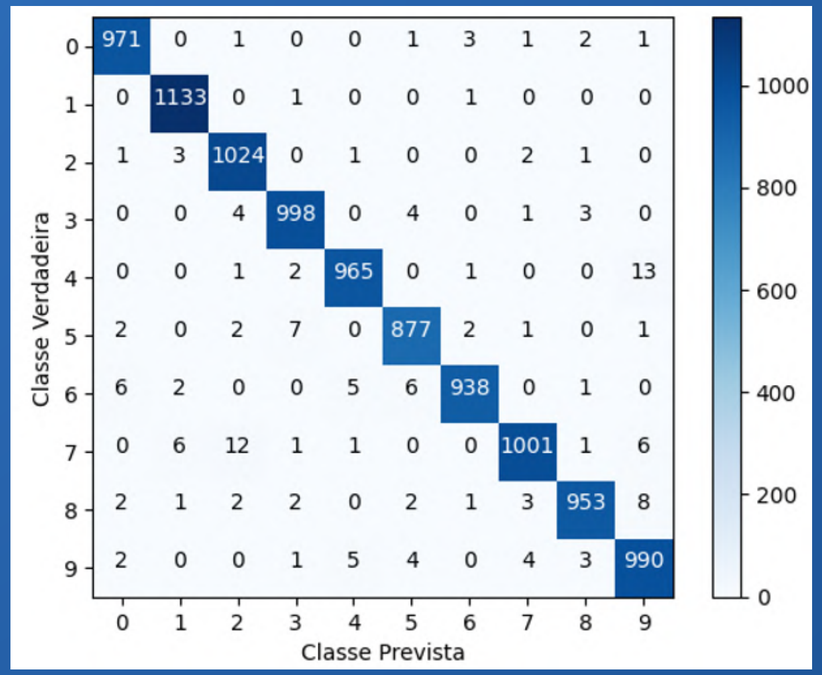

Resultados

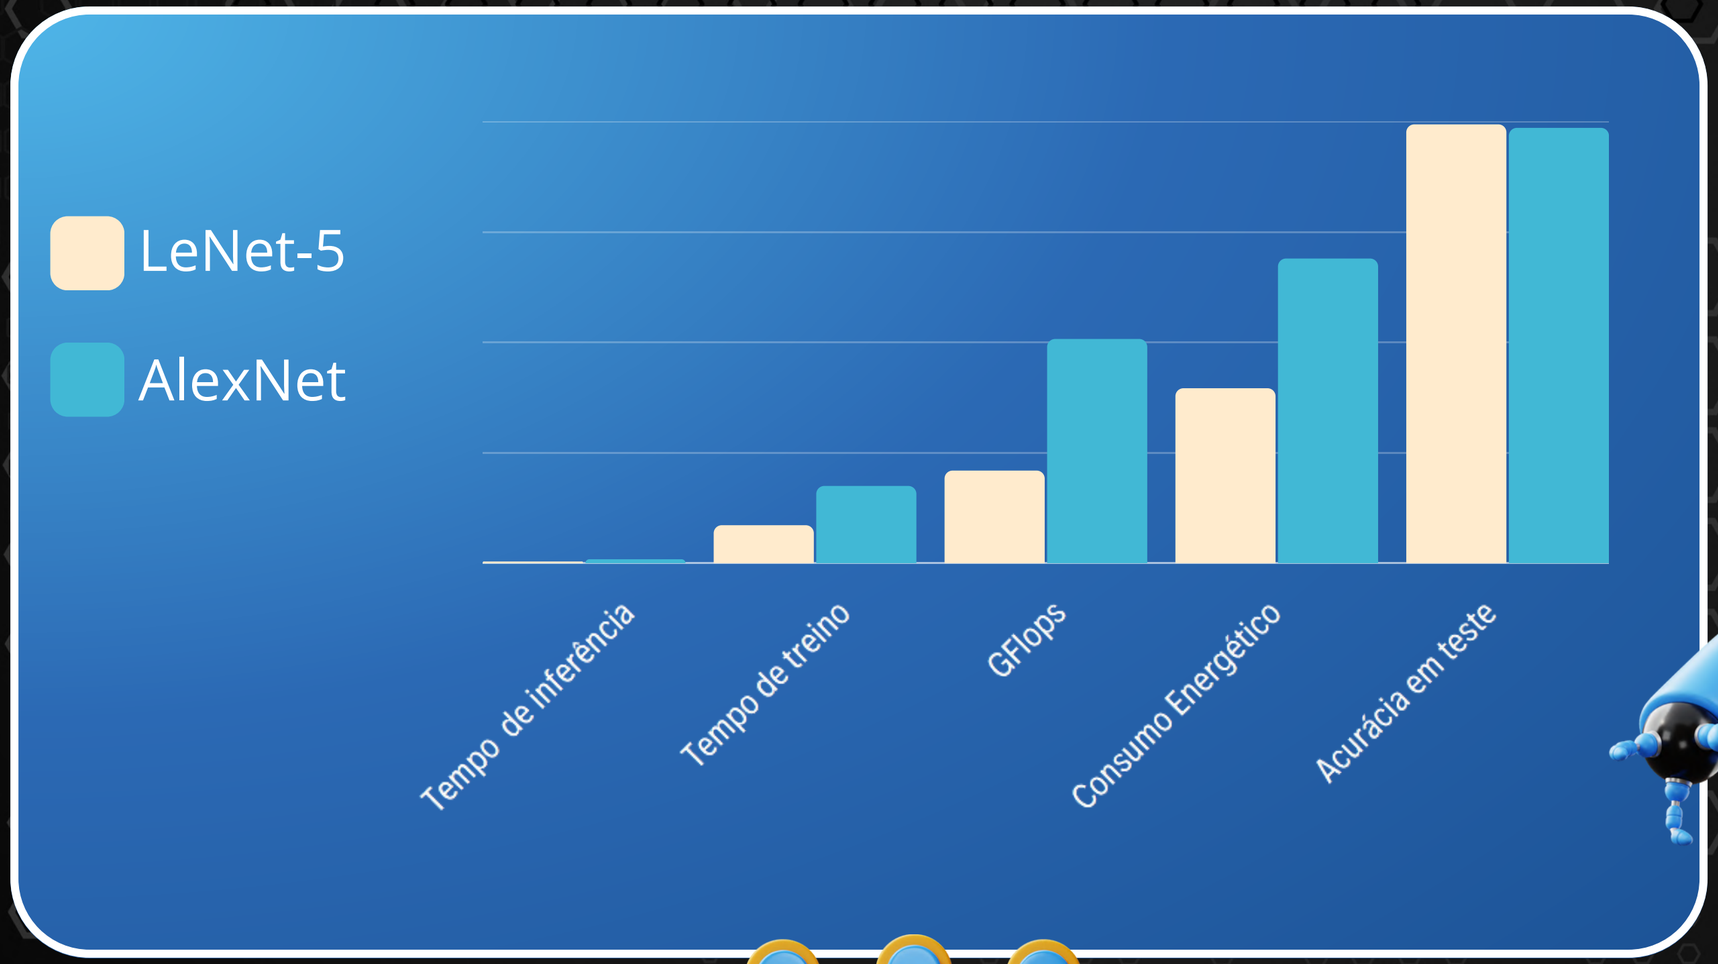
LeNet-5
AlexNet
Tempo de inferência
Tempo de treino
GFlops
Consumo Energético
Acurácia em teste

IA

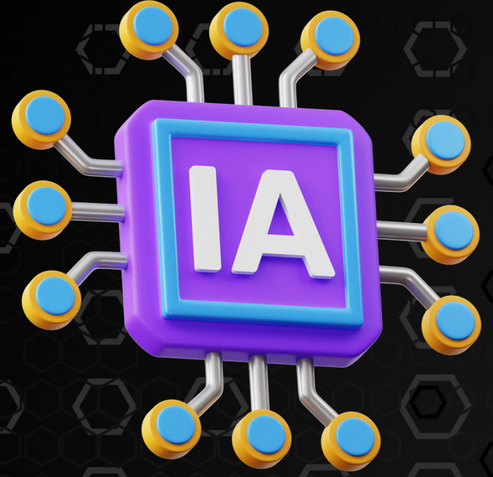

Conclusões

- Os resultados serviram para validar as métricas levantadas na literatura.
- Conforme esperado, os modelos gerados com a rede AlexNet apresentaram valores maiores nas métricas de consumo energético adotadas.
- Apesar disso, o modelo produzido pela rede AlexNet não apresentou o melhor desempenho nos testes realizados.
- Ressaltando a importância de se considerar não apenas o desempenho dos modelos.

“A IA verde é uma oportunidade de criar um futuro mais sustentável para todos. Ao desenvolver e usar sistemas de IA de forma responsável, podemos reduzir nosso impacto ambiental e proteger o planeta para as gerações futuras.”

Marc Benioff,
cofundador e CEO da Salesforce

Referências

- ANTHONY, Lasse F. Wolff; KANDING, Benjamin; SELVAN, Raghavendra. Carbontracker: tracking and predicting the carbon footprint of training deep learning models. arxiv preprint, arXiv:2007.03051, 2020.
- BRIOT, Jean-Pierre; HADJERES, Gaëtan; PACHET, François-David. Deep learning techniques for music generation. Heidelberg: Springer, 2020.
- DESISLAVOV, Radosvet; MARTÍNEZ-PLUMED, Fernando; HERNÁNDEZ-ORALLO, José. Trends in AI inference energy consumption: beyond the performance-vs-parameter laws of deep learning. Sustainable Computing: Informatics and Systems, [S.L.], v. 38, p. 100857, abr. 2023.
- DOUWES, Constance; ESLING, Philippe; BRIOT, Jean-Pierre. Energy consumption of deep generative audio models. arXiv preprint, arXiv:2107.02621, 2021.
- INRIA - Institut National de Recherche en Informatique et en Automatique. pyJoules 0.2.0 documentation. Disponível em: <https://pyjoules.readthedocs.io/en/latest/>. Acesso em: 22 ago. 2023.
- KRIZHEVSKY, Alex; SUTSKEVER, Ilya; HINTON, Geoffrey. ImageNet Classification with Deep Convolutional Neural Networks. Communications of the ACM, [S.L.], v. 60, n. 6, p. 84–90, 2017.
- KROHN, Jon; BEYLEVELD, Grant; BASSENS, Aglaé. Deep Learning Illustrated: a visual, interactive guide to artificial intelligence. Boston: Pearson Addison-Wesley, 2020. 416 p.
- LACOSTE, Alexandre; LUCCIONI, Alexandra; SCHMIDT, Victor; DANDRES, Thomas. Quantifying the carbon emissions of machine learning. arXiv preprint, arXiv:1910.09700, 2019.
- LECUN, Yann et al. Gradient-based learning applied to document recognition. Proceedings of the IEEE, v. 86, n. 11, p. 2278-2324, 1998.
- LENHERR, Nicola; PAWLITZEK, René; MICHEL, Bruno. New universal sustainability metrics to assess edge intelligence. Sustainable Computing: Informatics and Systems, [S.L.], v. 31, p. 100580, set. 2021.
- SCHWARTZ, Roy; DODGE, Jesse; SMITH, Noah A.; ETZIONI, Oren. Green AI. Communications of the ACM, [S.L.], v. 63, n. 12, p. 54-63, 2020.

Obrigada pela atenção!

Repositório do projeto no GitHub

viferraro@edu.unirio.br

Apresentação baseada no design ‘Blue and Black Futuristc Illustrative Artificial Intelligence project Presentation’, de Olmos Carlos e disponibilizado em https://www.canva.com.